Commercial-Vedio-Recognition

> Project:基于数据挖掘的tik tok商用广告视频识别
>
> Notebook From Kaggle
>
> Notebook From 阿里天池
>
> Dataset From Kaggle
>
> Dataset From 阿里天池

任务

- 为了吸引观众的注意力，广告视频的长度、音频、文本位置和画面会有与众不同之处。
- 我们将使用人工智能的方法构建一套商用广告识别系统来预测抖音短视频是否为商用广告，通过对Tik Tok平台上视频的时长、声音频谱、视频光谱、文字分布、画面变化等特征，进行特征抽取、特征过滤等方式处理后进行建模，来快速区分出投稿视频中的商业广告。
- 具体包括
  - 了解这份数据
  - 进行必要的数据清洗
  - 自由进行特征生成、特征选择、特征降维等工作
  - 建立合适的预测模型，并进行调参
  - 选用合适的方式进行模型集成，优化模型

数据

- 广告数据集包括5次采样、总长度为150小时的抖音视频中提取的视频镜头的标准视听特征，以270 fps的分辨率录制视频，分辨率为720 X 576。将视频数据处理为视频的时长、声音频谱、视频光谱、文字分布和画面变化等特征，以判断其是否为商用广告。最终的数据包含1个标签、230个特征。
- 数据提供了129685份视频的信息，储存在commercial_vedio_data.csv文件中，其中labels为标签。
- 数据集共包230个特征，涵盖视频的时长、声音频谱、视频光谱、文字分布和画面变化等方面。

> - 具体描述详见：数据集和变量说明.pdf

A. 视觉特征

- 视频镜头长度Length 1
- 每个视频镜头的屏幕文本分布Text 92-122
- 运动分布Move 2-3 18-58
- 帧差异分布Frame 4-5 59-91
- 边缘变化率Edge 4124-4125

B. 音频特征

- 短期能量Energe 6-7
- 零交叉率ZCR 8-9
- 光谱质心Centroid 10-11
- 光谱通量Flux 14-15
- 频谱滚降频率Rolloff 12-13
- 基频BasFreq 16-17
- 音频词包MFCC 123-4123

问题思路

数据集

- 观察数据的实际意义，发现所有数据都是连续型。
- 数据整体上分为两类，一类是期望、方差这种在意义上有高度概括性的数据；一类是第18-58、59-91、123-4123多个并列的特征。
- 标签分为两种，-1和+1，可以将-1调整为0，成为一个典型的分类问题

数据处理

- 数据中数字的尺度差异较小，可以不需要标准化
- 连续性变量不需要使用One-Hot编码
- 数据中存在大量的缺失值，严重影响完整性；可以预先将缺失值填充为均值，再通过特征的重要性判断是否有必要返回调整填充策略
- 数据中重复样本巨大，需要剔除
- 数据中有200+个特征，有必要进行选择，降低样本特征的维度；使用随机森林模型对特征重要性进行排序，对重要性排序图进行观察后调整输入模型的特征数量的超参数
- PCA能基于选择的特征融合出新的特征，期望与原数据合并之后提高预测能力
- 决策树驱动的特征分箱能在特征维度较高的情况下有利于快速迭代和稳定性，提高准确度并降低过拟合风险

模型建立

- 将数据输入随机森林分类器
- 通过ROC_AUC和Accuracy得分来评价生成的模型，反馈于模型的调参

模型准备

- 导入库

```
import numpy as np
import pandas as pd
from matplotlib import pyplot as plt
import seaborn as sns
%matplotlib inline
import warnings
```

- 导入数据集

```
# 导入文件依据运行的环境和平台进行必要的更改
data = pd.read_csv("../commercial_vedio_data.csv", index_col=0)
```

- 获得特征和标签

```
col_name = data.columns[:-2]
label_name = data.columns[-1]
print ('训练集的标签:{}\n'.format(label_name))
print ('训练集的特征:{}\n'.format(col_name))
print ('训练集的形状:{}\n'.format(data.shape))
```

```
>>output
训练集的标签:Label

训练集的特征:Index(['Length', 'Move_E', 'Move_D', 'Frame_E', 'Frame_D', 'Energe_E',
       'Energe_D', 'ZCR_E', 'ZCR_D', 'Centroid_E',
       ...
       '882', '924', '959', '1002', '1016', '1028', '1048', '1112', '1119',
       'Edge_E'],
      dtype='object', length=229)

训练集的形状:(129685, 231)
```

- 重命名标签

```
# Rename
data.rename(columns={'1':'Length', '2':'Move_E', '3':'Move_D', '4':'Frame_E', '5':'Frame_D',
'6':'Energe_E', '7':'Energe_D', '8':'ZCR_E', '9':'ZCR_D', '10':'Centroid_E', '11':'Centroid_D',
'12':'Rolloff_E', '13':'Rolloff_D', '14':'Flux_E', '15':'Flux_D', '16':'BasFreq_E', '17':'BasFreq_D',
'4124':'Edge_E', '4125':'Edge_D', 'labels':'Label'}, inplace=True)
```

数据分析

- 数据整体描述
  - 整体来说数据的尺度较为一致
  - 在Length特征中存在有异常值，应该清除

```
data.head()
data.describe()
```

	Length	Move_E	Move_D	Frame_E	Frame_D	Energe_E	Energe_D	ZCR_E	ZCR_D	Centroid_E	...	959	1002	1016	1028	1048	1112	1119	Edge_E	Edge_D	Label	
0	123	1.316440	1.516003	5.605905	5.346760	0.013233	0.010729	0.091743	0.050768	3808.067871	...	0.036017	0.006356	0.008475	NaN	0.002119	NaN	NaN	0.422334	0.663918	1	
1	124	0.966079	0.546420	4.046537	3.190973	0.008338	0.011490	0.075504	0.065841	3466.266113	...	0.117647	0.006303	NaN	NaN	0.008403	NaN	NaN	0.332664	0.766184	1	
2	109	2.035407	0.571643	9.551406	5.803685	0.015189	0.014294	0.094209	0.044991	3798.196533	...	0.062500	0.004808	NaN	NaN	NaN	0.009615	NaN	0.346674	0.225022	1	
3	86	3.206008	0.786326	10.092709	2.693058	0.013962	0.011039	0.092042	0.043756	3761.712402	...	0.046296	0.012346	NaN	NaN	0.012346	0.003086	NaN	0.993323	0.840083	1	
4	76	3.135861	0.896346	10.348035	2.651010	0.020914	0.012061	0.108018	0.052617	3784.488037	...	NaN	0.003521	NaN	NaN	0.045775	0.007042	NaN	0.341520	0.710470	1	

	Length	Move_E	Move_D	Frame_E	Frame_D	Energe_E	Energe_D	ZCR_E	ZCR_D	Centroid_E	...	959	1002	1016	1028	1048	1112	1119	Edge_E	Edge_D
count	129685.000000	129685.000000	129685.000000	129685.000000	129685.000000	129685.000000	129685.000000	129685.000000	129685.000000	129685.000000	...	62719.000000	53351.000000	41920.000000	1860.000000	55528.000000	13108.000000	217.000000	129685.000000	129685.00000
mean	106.400000	2.587003	1.601049	11.918077	8.264462	0.015218	0.009762	0.103230	0.056772	3481.604677	...	0.044993	0.040969	0.055489	0.003688	0.035440	0.006209	0.036149	0.500648	0.500378
std	264.814882	2.179930	1.374998	9.068333	6.847135	0.005434	0.003281	0.037289	0.021509	669.086147	...	0.056405	0.049836	0.069591	0.004812	0.043293	0.012654	0.075509	0.288909	0.288068
min	25.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	...	0.000059	0.000059	0.000073	0.000014	0.000007	0.000047	0.000271	0.000032	0.000003
25%	30.000000	0.947497	0.674715	5.380625	3.244237	0.012589	0.008073	0.083190	0.045150	3390.920654	...	0.011161	0.008621	0.009770	0.000836	0.009804	0.001208	0.004464	0.250215	0.251995
50%	49.000000	1.970185	1.343323	9.476908	6.584897	0.015709	0.010057	0.102859	0.054889	3608.322998	...	0.025000	0.023585	0.028226	0.001988	0.022727	0.002687	0.012500	0.501763	0.499753
75%	96.000000	3.710244	2.163196	16.568928	11.572393	0.018552	0.012005	0.123875	0.066628	3774.575684	...	0.057143	0.056830	0.076539	0.004556	0.045455	0.006410	0.037500	0.751095	0.749926
max	33871.000000	21.679216	37.363274	67.285736	63.396584	0.036905	0.021416	0.394551	0.246353	4005.922607	...	0.812500	0.637500	1.012500	0.050000	0.840909	0.223214	0.512500	0.999973	0.999997

- 查看分布

```
# Label分布的直方图
sns.distplot(data['Label'], kde=False)
```

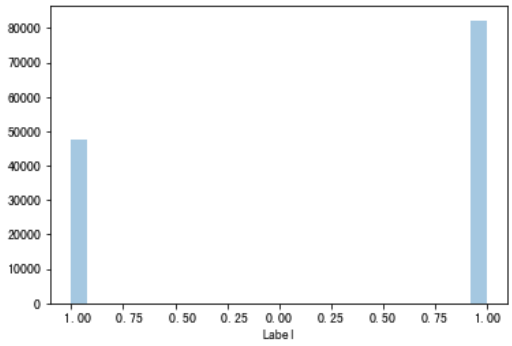


```
# 时长Length分布和统计
data.drop(data[data['Length'] > 10000].index.tolist(), inplace=True)
fig, axes = plt.subplots(1, 2)
sns.barplot(x='Label', y='Length', data=data, ax=axes[0])
sns.stripplot(x='Label', y='Length', data=data, ax=axes[1], jitter=True)
plt.show()
# 商业广告和非商业广告的长度分布
facet = sns.FacetGrid(data[['Length', 'Label']], hue='Label', aspect=2)
facet.map(sns.kdeplot, "Length", shade=True)
facet.set(xlim=(0, 500))
facet.add_legend()
facet.set_axis_labels("Length", "Density")
```

> 图为商业广告和非商业广告的长度分布

- 可以看出是否为商业广告在视频长度上有着相似的分布，但又存在着不同
- 通过图表可以发现有异常数据，剔除后显示如下

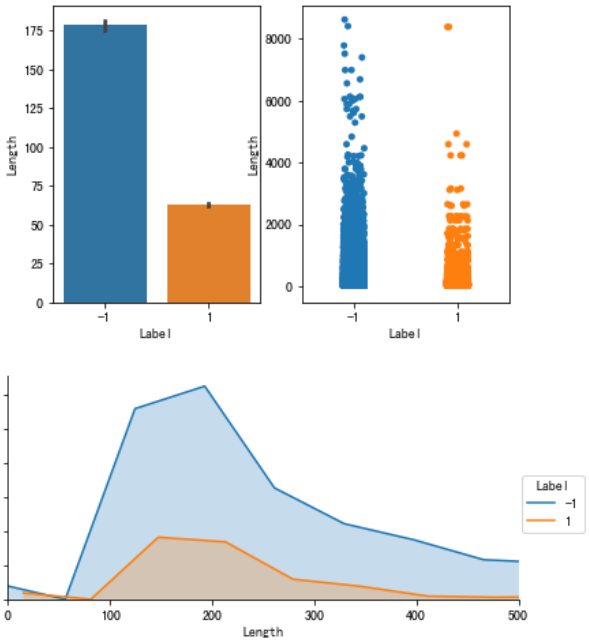

清洗数据

查看、填充缺失值

```
data.isnull().any()
```

```
>>output
Length     False
Move_E     False
Move_D     False
Frame_E    False
Frame_D    False
           ...
1112        True
1119        True
Edge_E     False
Edge_D     False
Label      False
Length: 231, dtype: bool
```

去除重复样本

- 样本中存在高达上千的重复样本，去除后有利于模型精准度

```
data.drop_duplicates(inplace=True)
data.shape
```

```
>>output
(111615, 231)
```

填充缺失样本

- 暂时以平均值进行填充
- 若填充的这些特征不重要则可以保持
- 反之，应该通过无缺失的特征对缺失特征进行简单预测

```
data = data.fillna(data.mean())
```

更改标签

```
# Label -1 -> 0
data['Label'] = data['Label'].apply(lambda x:0 if x == -1 else x)
data['Label'].hist()
```

> 通过柱形图可以简单观察到标签修改完成

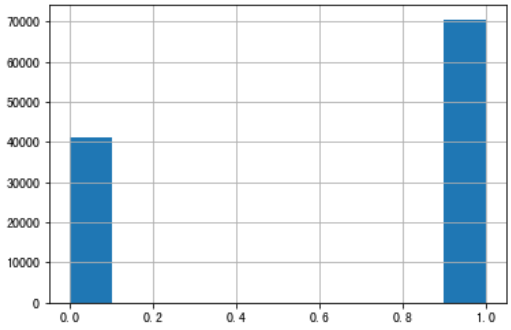

哑变量

- 无离散型变量，无需get_dummies

特征工程

> 可综合多种方法进行特征工程
>
> - 一是使用某些方法生成新的特征纳入模型进行预测
> - 二是通过某些方法进行特征过滤，减少纳入模型的特征数量
> - 三是对连续特征进行特征分箱，离散特征进行特征组合。

> - 特征过滤
> - 特征生成
> - 特征分箱

- 分离特征和标签

```
X = data.drop(['Label'], axis=1)
Y = data['Label']
```

- 划分训练集和测试集

```
from sklearn.model_selection import train_test_split
xtrain, xtest, ytrain, ytest = train_test_split(X, Y, train_size=0.75)
```

特征选择

- 使用随机森林进行特征选择
- 训练集拟合随机森林模型
- 用于获得feature_importances_

```
from sklearn.ensemble import RandomForestClassifier
rfcModel = RandomForestClassifier()
rfcModel.fit(xtrain, ytrain)
```

特征重要性排序

> 通过重要性值进行排序画出柱状图
>
> 通过计算前缀和画出阶梯图
>
> 前缀和阶梯图可以直观地看出所选的特征模型的累计贡献，给特征选择的超参数调整参考

```
# 将特征的重要性程度进行排序
N_most_important = 25

imp = np.argsort(rfcModel.feature_importances_)[::-1]
imp_slct = imp[:N_most_important]

FeaturesImportances = zip(col_name, map(lambda x:round(x,5), rfcModel.feature_importances_))
FeatureRank = pd.DataFrame(columns=['Feature', 'Imp'], data=sorted(FeaturesImportances, key=lambda
x:x[1], reverse=True)[:N_most_important])

# 重新选择X
xtrain_slct = xtrain.iloc[:,imp_slct]
xtest_slct  = xtest.iloc[:,imp_slct]

# 特征排序图
ax1 = fig.add_subplot(111)
ax1 = sns.barplot(x='Feature', y='Imp', data=FeatureRank)
ax1.set_xticklabels(ax1.get_xticklabels(), rotation=90)

SumImp = FeatureRank
for i in SumImp.index:
    if (i==0):
        SumImp['Imp'][i] = FeatureRank['Imp'][i]
    else:
        SumImp['Imp'][i] = SumImp['Imp'][i-1] + FeatureRank['Imp'][i]
ax2 = ax1.twinx()
plt.step(x=SumImp['Feature'], y=SumImp['Imp'])
```

> 特征排序和前缀和阶梯图

- 可以看出前3个特征对于模型有着相对高的贡献，但是累计的贡献不足
- 在排序后的第25个特征附近的特征的重要性仅仅有重要程度最高的特征的10%
- 因此在保证特征充足、又简化模型复杂度的情况下，我选择前25个特征进行建模

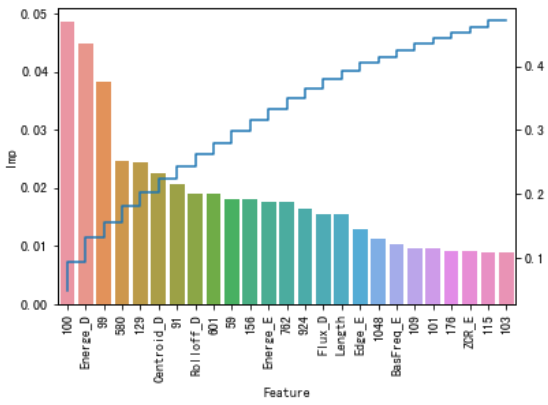

PCA

> 使用PCA进行特征生成，即与选择出的主成分与原数据合并，能够一定程度上提高预测精准度
> 对训练集使用PCA生成新特征，根据累计贡献率，保留前5个主成分
> 对测试集进行相同的操作，注意测试集上直接使用pca中的transform函数，相同方法处理训练集和测试集

```
from sklearn.decomposition import PCA
pca = PCA(n_components=N_most_important)
pca.fit(xtrain)
pca.explained_variance_ratio_
```

```
>>output
>>array([6.44019353e-01, 1.91966700e-01, 1.31533910e-01, 1.94097858e-02,
       7.15686452e-03, 5.11195793e-03, 6.94964416e-04, 7.23740187e-05,
       2.35382455e-05, 6.08344172e-06, 3.61950934e-06, 6.11507427e-07,
       9.72953450e-08, 2.07865426e-08, 2.06120726e-08, 2.01479207e-08,
       1.26524838e-08, 7.37201378e-09, 5.68464881e-09, 5.41418107e-09,
       4.50735308e-09, 3.67000625e-09, 3.15899020e-09, 3.00134603e-09,
       2.56423139e-09])
```

- 对训练集使用PCA生成新特征，根据累计贡献率，保留前6个主成分

```
pca1 = PCA(6)
pc = pd.DataFrame(pca1.fit_transform(xtrain))
pc.index = xtrain.index
xtrain_pca = xtrain.join(pc)
```

- 对测试集进行相同的操作，注意测试集上直接使用pca中的transform函数

```
pc = pd.DataFrame(pca1.fit_transform(xtest))
pd.index = xtrain.index
xtest_pca = xtest.join(pc)
```

特征分箱

> 使用cut_bin和cut_test_bin基于决策树进行分箱
> 重新获得训练集和测试集

- 使用决策树进行特征分箱
  - 通过特征分箱可以将连续性的数据转换为离散型数据
  - 提高模型稳定性
  - 降低过拟合风险

> 调整决策树参数中
>
> 决策树最大深度应在10-100之间，提高到一定值后，优化效果不显著
>
> 最小叶子节点数与样本量的比例在大于0.3的情况下会降低分箱效果

```
from sklearn.tree import DecisionTreeClassifier
train = xtrain.join(ytrain)
test  = xtest.join(ytest)
new_train, train_dict_bin = cut_bin(train, 'Label', 50, 0.2)
new_test , test_dict_bin  = cut_test_bin(test, 'Label', train_dict_bin)
```

- 分离特征和标签

```
xtrain = new_train.drop(['Label'], axis=1)
xtest  = new_test.drop(['Label'] , axis=1)
ytrain = new_train['Label']
ytest  = new_test['Label']
```

- 特征分箱函数

```
#  cut_bin对训练集进行分箱
def cut_bin(df,label,max_depth,p):
    df_bin = df[[label]]
    df_feature = df.drop([label],axis=1)
    dict_bin = {}
    for col in df_feature.columns:
        get_model = DecisionTreeClassifier(max_depth=max_depth,min_samples_leaf=int(p*len(df)))
        get_cut_point = get_model.fit(df[col].values.reshape(-1,1),df[label].values.reshape(-1,1))
        cut_point = get_cut_point.tree_.threshold[get_cut_point.tree_.threshold!=-2]
        N_split = np.zeros_like(df[col])
        inter_range = []
        if len(cut_point)==1:
            N_split[np.array(df[col]<cut_point[0])]=1
            N_split[np.array(df[col]>=cut_point[0])]=2
            inter_range=[[1,-100000000,cut_point[0]],[2,cut_point[0],100000000]]
        elif len(cut_point)>1:
            cut_point.sort()
            N_split[np.array(df[col]<cut_point[0])]=1
            inter_range=[[1,-100000000,cut_point[0]]]
            for i in range(len(cut_point)-1):
                N_split[np.array((df[col]>=cut_point[i]) & (df[col]<cut_point[i+1]))]=i+2
                inter_range=inter_range+[[i+2,cut_point[i],cut_point[i+1]]]
            N_split[np.array(df[col]>=cut_point[len(cut_point)-1])]=len(cut_point)+1
            inter_range=inter_range+[[len(cut_point)+1,cut_point[len(cut_point)-1],100000000]]
        else:
            N_split=1
            inter_range=np.array([1,-100000000,100000000]).reshape(1,-1)
        df_bin[col] = N_split
        inter_df = pd.DataFrame(inter_range)
        inter_df.columns=['bin','lower','upper']
        crosstable = pd.crosstab(df_bin[col],df_bin[label])
        crosstable.columns = ['notCommercial','Commercial']
        crosstable['all'] = crosstable['notCommercial']+crosstable['Commercial']
        crosstable['percent'] = crosstable['all']/sum(crosstable['all'])
        crosstable['c_rate'] = crosstable['Commercial']/crosstable['all']
        inter_df = pd.merge(inter_df, crosstable, left_on='bin', right_index=True)
        dict_bin[col] = inter_df
    return df_bin, dict_bin

#  cut_test_bin对测试集进行分箱
```

```
def cut_test_bin(df, label, train_dict_bin):
    df_bin = df[[label]]
    df_feature = df.drop([label],axis=1)
    dict_bin = {}
    for col in df_feature.columns:
        train_bin = train_dict_bin[col]
        splited = pd.Series([np.nan]*len(df[col]))
        for i in range(len(train_bin['bin'])):
            splited[((df[col]>=train_bin['lower'][i]) & (df[col]<train_bin['upper'][i])).tolist()]=train_bin['bin'][i]
            df_bin[col]=splited.tolist()
        crosstable = pd.crosstab(df_bin[col],df_bin[label])
        crosstable.columns = ['notCommercial','Commercial']
        crosstable['all'] = crosstable['notCommercial']+crosstable['Commercial']
        crosstable['percent'] = crosstable['all']/sum(crosstable['all'])
        crosstable['c_rate'] = crosstable['Commercial']/crosstable['all']
        inter_df = pd.merge(train_bin[['bin','lower','upper']], crosstable, left_on='bin', right_index=True, how='left')
        dict_bin[col] = inter_df
    return df_bin, dict_bin
```

训练模型

> 基于以上的特征工程进行模型训练

- 使用随机森林分类器
- 预设参数为
  - max_features=16
  - max_depth=12
  - n_estimators=2048
  - n_jobs=-1
  - random_state=0

```
# 随机森林分类器训练模型
from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier(max_features=16,max_depth=12,n_estimators=2048,n_jobs=-1,random_state=0)
rf.fit(xtrain, ytrain)
```

模型评估

- 评价训练集表现
- 评价测试集表现
- 随机猜测函数对比

```
from sklearn.metrics import confusion_matrix
from sklearn.metrics import roc_auc_score, accuracy_score

# AUC和混淆矩阵评估
ytrain_pred_clf = rf.predict_proba(xtrain)
ytrain_pred = rf.predict(xtrain)
ytest_pred_clf = rf.predict_proba(xtest)
ytest_pred = rf.predict(xtest)

# 评估训练集效果，直观判断是否过拟合
print ('分类模型训练集表现：')
print ('ml train model auc score {:.6f}'.format(roc_auc_score(ytrain, ytrain_pred_clf[:,1])))
print ('-------------------------------')
print ('ml train model accuracy score {:.6f}'.format(accuracy_score(ytrain, ytrain_pred)))
print ('-------------------------------')
threshold = 0.5
print (confusion_matrix(ytrain, (ytrain_pred_clf>threshold)[:,1]))

# 评估测试集效果
print ('分类模型测试集表现：')
print ('ml model auc score {:.6f}'.format(roc_auc_score(ytest, ytest_pred_clf[:,1])))
print ('-------------------------------')
print ('ml model accuracy score {:.6f}'.format(accuracy_score(ytest, ytest_pred)))
print ('-------------------------------')
threshold = 0.5
print (confusion_matrix(ytest, (ytest_pred_clf>threshold)[:,1]))

# 随机猜测函数对比
ytest_random_clf = np.random.uniform(low=0.0, high=1.0, size=len(ytest))
print ('random model auc score {:.6f}'.format(roc_auc_score(ytest, ytest_random_clf)))
print ('-------------------------------')
print (confusion_matrix(ytest, (ytest_random_clf<=threshold).astype('int')))
```

```
>>output
>>分类模型训练集表现：
```

```
ml train model auc score 0.979045
------------------------------
ml train model accuracy score 0.926605
------------------------------
[[26550  4049]
 [ 2095 51017]]
分类模型测试集表现:
ml model auc score 0.957583
------------------------------
ml model accuracy score 0.895033
------------------------------
[[ 8414  2030]
 [  899 16561]]
random model auc score 0.505389
------------------------------
[[5105 5339]
 [8671 8789]]
```

> 测试集上模型的表现较为优秀，ROC_AUC和Accuracy分别达到了96%和90%的分数

项目总结

> 通过对于视频提取的数据的异常处理和清洗，依据随机森林模型的重要性排序选择有效贡献于标签的特征，用PCA融合出新的显著特征，在基于决策树对离散数据分箱，输入随机森林分类器后评价准确率最高达到了96%，可以认为较好的完成了对商业广告视频的识别。